

Analiza i przetwarzanie dźwięku

Projekt 2 – Analiza częstotliwościowa sygnałów audio

Sprawozdanie z projektu

Autorzy:

Bartosz Radomski, Wiktor Pańczak

Spis treści

1	Wstęp	3
2	Cel projektu i zakres wykonania	3
3	Opis aplikacji	4
3.1	Technologie i biblioteki	4
3.2	Interfejs użytkownika	4
4	Przebieg działania programu	4
5	Opis metod i implementacji	5
5.1	Wczytanie i normalizacja sygnału	5
5.2	Podział na ramki i nakładanie ramek	6
5.3	Funkcje okienkowe	6
5.4	Szybka transformata Fouriera	7
5.5	Centroid widmowy	8
5.6	Szerokość widmowa	8
5.7	Spectral roll-off	8
5.8	Płaskość widmowa	8
5.9	Spektrogram	9
5.10	Cepstrum i częstotliwość tonu podstawowego	9
5.11	Formanty	10
6	Plan eksperymentów	11
6.1	Zestaw nagrań testowych	11
6.2	Ustawienia bazowe	11
7	Wyniki działania programu	12
7.1	Porównanie formantów aba i abe	12
7.2	Porównanie spektrogramu i tonu podstawowego różnych lektorów	13
7.3	Spektrogram i inne parametry spółgłosek bezdźwięcznych	14

8	Dyskusja wyników	14
8.1	Różnice między analizą czasową i częstotliwościową	14
8.2	Obserwacje dla samogłosek i spółgłosek	15
8.3	Ograniczenia metod	15
9	Problemy napotkane podczas realizacji	15
10	Wnioski	16

1 Wstęp

Celem projektu było rozszerzenie aplikacji przygotowanej w pierwszym projekcie o analizę sygnału audio w dziedzinie częstotliwości. Program zachowuje funkcje wcześniejszej wersji, takie jak wczytywanie plików **WAV**, rysowanie przebiegu czasowego, wyznaczanie cech ramkowych w dziedzinie czasu oraz eksport wyników, a dodatkowo umożliwia analizę widmową, zastosowanie funkcji okienkowych, rysowanie spektrogramu i wyznaczanie częstotliwości tonu podstawowego metodą cepstralną.

Analiza częstotliwościowa jest istotna, ponieważ wiele właściwości sygnałów mowy i muzyki nie jest bezpośrednio widocznych na przebiegu czasowym. Widmo pozwala zauważyć obecność składowych harmonicznym, rozkład energii w paśmie, wpływ okienkowania oraz różnice pomiędzy głoskami dźwięcznymi, bezdźwięcznymi i samogłoskami. Spektrogram rozszerza tę analizę o wymiar czasu, dzięki czemu można obserwować zmiany widma w kolejnych fragmentach nagrania.

2 Cel projektu i zakres wykonania

W projekcie należało stworzyć aplikację realizującą analizę częstotliwościową sygnałów dźwiękowych. Wykonana aplikacja jest rozwinięciem projektu 1 i obejmuje następujące funkcje:

1. wczytywanie i normalizację plików **WAV**,
2. rysowanie przebiegu sygnału w dziedzinie czasu,
3. podział sygnału na ramki o zadanej długości oraz opcjonalnym nakładaniu,
4. obliczanie parametrów z dziedziny czasu: *volume*, *short-time energy*, *zero crossing rate*, detekcja ciszy, fragmenty dźwięczne i bezdźwięczne, klasyfikacja mowa/muzyka,
5. rysowanie widma częstotliwościowego z wykorzystaniem FFT,
6. analizę całego sygnału lub wybranego fragmentu sygnału o zadanym czasie początku i długości,
7. zastosowanie funkcji okienkowych i porównanie przebiegu oraz widma przed i po okienkowaniu,
8. wybór okna prostokątnego, trójkątnego, Hamminga, Hanny oraz Blackmana,
9. obliczanie i rysowanie parametrów widmowych: centroidu widmowego, szerokości widmowej, roll-off oraz płaskości widmowej,
10. samodzielne utworzenie spektrogramu na podstawie widm kolejnych ramek,

11. obliczanie częstotliwości tonu podstawowego metodą cepstrum,
12. zapis wyników analizy do plików CSV i TXT.

3 Opis aplikacji

3.1 Technologie i biblioteki

Aplikacja została napisana w języku **Python**. Tak jak w poprzednim projekcie wykorzystano **tkinter** do budowy interfejsu graficznego, **scipy.io.wavfile** do wczytywania plików WAV, **numpy** do operacji numerycznych oraz **matplotlib** do rysowania wykresów. Do wyznaczania widma zastosowano funkcję FFT dostępną w bibliotece **numpy**. Jest to zgodne z założeniami projektu, ponieważ wymagania dopuszczały użycie biblioteki do samej transformaty FFT, natomiast sposób przygotowania ramek, okienkowanie, obliczenie cech widmowych i spektrogram zostały zrealizowane w kodzie aplikacji.

Program jest uruchamiany przez plik **project1.py**, który wywołuje funkcję startującą interfejs graficzny. Właściwa logika aplikacji została podzielona na moduły odpowiedzialne za obsługę wejścia audio, cechy czasowe, cechy widmowe, analizę sygnału oraz interfejs użytkownika. Taki podział ułatwia rozbudowę programu, ponieważ funkcje obliczeniowe są oddzielone od kodu odpowiedzialnego za okno aplikacji.


3.2 Interfejs użytkownika

Interfejs programu składa się z kilku grup kontroltek. W górnej części użytkownik wybiera plik WAV. Następnie dostępne są ustawienia długości ramki, nakładania ramek, progów detekcji ciszy oraz maksymalnej częstotliwości prezentowanej na spektrogramie. Osobna sekcja pozwala wybrać wykresy parametrów czasowych, a kolejna sekcja dotyczy parametrów widmowych.

W części *FFT i okna* użytkownik może wybrać, czy analiza FFT ma zostać wykonana dla całego sygnału, czy tylko dla fragmentu o zadanym początku i długości. Można również wskazać funkcję okienkową oraz zdecydować, czy na wykresie mają zostać pokazane przebieg po okienkowaniu i widmo po okienkowaniu. Wyniki zbiorcze dla klipu są prezentowane w polu tekstowym, a dodatkowo można je zapisać do plików.

4 Przebieg działania programu

Po wybraniu pliku WAV aplikacja odczytuje częstotliwość próbkowania oraz próbki sygnału. Jeżeli nagranie jest stereofoniczne, kanały są sumowane do jednego sygnału. Następnie



Rysunek 1: Zrzut ekranu głównego okna aplikacji po wczytaniu pliku WAV, z widocznymi ustawieniami ramki, overlapu, parametrów widmowych oraz sekcją FFT i okna.

próbki są przeskalowywane do postaci zmiennoprzecinkowej, zależnie od oryginalnego typu danych.

Dalsze działanie programu można podzielić na dwa tryby. Pierwszy tryb, uruchamiany przyciskiem *Rysuj wykresy*, wykonuje analizę ramkową: oblicza cechy czasowe i widmowe dla kolejnych ramek, tworzy spektrogram oraz przygotowuje parametry całego klipu. Drugi tryb, uruchamiany przyciskiem *Rysuj FFT*, służy do szczegółowej analizy widma całego nagrania albo wskazanego fragmentu.

Schemat działania można zapisać następująco:

Wczytanie WAV → normalizacja próbek → wybór trybu analizy → ramkowanie i/lub wybór fragmentu → okienkowanie → FFT → obliczenie cech widmowych → wykresy, spektrogram i eksport wyników

5 Opis metod i implementacji

5.1 Wczytanie i normalizacja sygnału

Wczytywanie pliku realizowane jest za pomocą funkcji `wavfile.read`. Próbkę są zamieniane na typ `float32`. Dla danych 8-bitowych wykonywane jest przesunięcie względem poziomu 128 i normalizacja przez 128, a dla próbek 16- i 32-bitowych stosowane jest dzielenie przez odpowiednio 2^{15} albo 2^{31} . Dzięki temu dalsze obliczenia mogą być prowadzone na wartościach o porównywalnym zakresie.

Dla sygnału stereo zastosowano sumowanie kanałów:

$$x[n] = x_L[n] + x_R[n]. \quad (1)$$

Upraszczając to analizę, ponieważ wszystkie późniejsze funkcje pracują na jednym przebiegu czasowym.

5.2 Podział na ramki i nakładanie ramek

Dla analiz ramkowych sygnał dzielony jest na krótkie fragmenty. Długość ramki w próbkach wynosi:

$$N = \frac{f_s \cdot T}{1000}, \quad (2)$$

gdzie f_s oznacza częstotliwość próbkowania, a T długość ramki w milisekundach.

W projekcie dodano możliwość ustawienia procentowego nakładania ramek. Jeżeli overlap wynosi p procent, przesunięcie ramki jest równe:

$$H = N - \frac{p}{100}N. \quad (3)$$

Większy overlap zwiększa liczbę analizowanych ramek i daje płynniejszy spektrogram, ale powoduje większy koszt obliczeniowy. Wartość overlapu musi być mniejsza niż 100%, ponieważ przy 100% przesunięcie ramki byłoby równe zero.

5.3 Funkcje okienkowe


Przed obliczeniem FFT wybrany fragment sygnału może zostać pomnożony przez funkcję okienkową:

$$x_w[n] = x[n] \cdot w[n]. \quad (4)$$

Okienkowanie ogranicza nieciągłości na brzegach analizowanego fragmentu. Bez okna, albo przy oknie prostokątnym, fragment jest gwałtownie ucinany, co może powodować przeciek widma. Okna o wygładzonych brzegach zmniejszają ten efekt, ale jednocześnie poszerzają główną wiązkę widma i mogą obniżać amplitudy składowych.

W aplikacji zaimplementowano następujące okna:

- prostokątne – brak wygładzania, $w[n] = 1$,
- trójkątne – okno o liniowo rosnącej i malejącej wartości,
- Hamminga,
- Hanny,
- Blackmana.



Rysunek 2: Porównanie przebiegu czasowego i FFT wybranego fragmentu przed i po zastosowaniu okna.

Dla okna Hamminga stosowany jest typowy kształt:

$$w[n] = 0,54 - 0,46 \cos\left(\frac{2\pi n}{N-1}\right), \quad (5)$$

a dla okna Hann:

$$w[n] = 0,5 - 0,5 \cos\left(\frac{2\pi n}{N-1}\right). \quad (6)$$

5.4 Szybka transformata Fouriera

Widmo częstotliwościowe jest obliczane za pomocą FFT. Dla sygnału dyskretnego $x[n]$ transformata Fouriera ma postać:

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j2\pi kn/N}. \quad (7)$$

W programie wykorzystywana jest rzeczywista wersja transformaty, ponieważ analizowane próbki są rzeczywiste. Oś częstotliwości tworzona jest na podstawie częstotliwości próbkowania:

$$f_k = \frac{k f_s}{N}. \quad (8)$$

Do rysowania widma używana jest znormalizowana wartość modułu:

$$M[k] = \frac{|X[k]|}{N}. \quad (9)$$

Taki sposób prezentacji pozwala porównywać widma fragmentów o różnych długościach.

5.5 Centroid widmowy

Centroid widmowy opisuje środek ciężkości widma. Dla wektora częstotliwości f_k i modułu widma $M[k]$ obliczany jest jako:

$$C = \frac{\sum_k f_k M[k]}{\sum_k M[k]}. \quad (10)$$

Wysoka wartość centroidu oznacza, że większa część energii znajduje się w wyższych częstotliwościach. Parametr ten może być większy dla głosów szumowych, spółgłosek bezdźwięcznych lub sygnałów o jasnym brzmieniu.

5.6 Szerokość widmowa

Szerokość widmowa określa rozproszenie widma względem centroidu:

$$B = \sqrt{\frac{\sum_k (f_k - C)^2 M[k]}{\sum_k M[k]}}. \quad (11)$$

Mała wartość oznacza, że energia jest skupiona w wąszym zakresie częstotliwości. Duża wartość oznacza widmo bardziej rozproszone, typowe dla szumu, spółgłosek szczelinowych lub fragmentów z wieloma składowymi.

5.7 Spectral roll-off

Parametr *spectral roll-off* wyznacza częstotliwość, poniżej której znajduje się określony procent energii widma. W implementacji zastosowano domyślnie 85%:

$$\sum_{k=0}^{K_r} M^2[k] \geq 0,85 \sum_k M^2[k]. \quad (12)$$


Wynikiem jest częstotliwość f_{K_r} . Parametr ten dobrze pokazuje, czy znaczna część energii sygnału znajduje się w niskich, czy wysokich częstotliwościach.

5.8 Płaskość widmowa

Płaskość widmowa porównuje średnią geometryczną widma ze średnią arytmetyczną:

$$F = \frac{\exp\left(\frac{1}{N} \sum_k \ln M[k]\right)}{\frac{1}{N} \sum_k M[k]}. \quad (13)$$

Wartości bliższe zero oznaczają widmo tonalne, z wyraźnymi maksimami. Wartości bliższe



Rysunek 3: Spektrogram nagrania mowy dla okna Hann, długości ramki 80 ms i overlapu 50%.

jedności oznaczają widmo bardziej szumowe. W implementacji zastosowano małą wartość zabezpieczającą, aby uniknąć logarytmowania zera.

5.9 Spektrogram

Spektrogram przedstawia zmienność widma w czasie. Program tworzy go samodzielnie przez obliczenie widma FFT dla kolejnych ramek sygnału. Dla każdej ramki wykonywane są kroki:

1. pobranie fragmentu sygnału,
2. pomnożenie go przez wybraną funkcję okna,
3. obliczenie modułu widma FFT,
4. zapisanie widma jako kolejnej kolumny macierzy spektrogramu.


Macierz spektrogramu można zapisać jako:

$$S[m, k] = |\mathcal{F}\{x[mH + n]w[n]\}|, \quad (14)$$

gdzie m oznacza numer ramki, k numer koszyka częstotliwości, a H przesunięcie między ramkami. Program pozwala ograniczyć maksymalną częstotliwość prezentowaną na spektrogramie, co poprawia czytelność dla sygnałów mowy, ponieważ wiele istotnych informacji znajduje się w niższych pasmach.

5.10 Cepstrum i częstotliwość tonu podstawowego

W projekcie 1 ton podstawowy był wyznaczany metodą autokorelacji i AMDF. W projekcie 2 dodano metodę cepstralną. Najpierw obliczane jest widmo amplitudowe, następnie



Rysunek 4: Porównanie spektrogramu dla dwóch różnych długości ramek: 20 ms i 80 ms, przy tym samym nagraniu.


logarytm widma, a potem odwrotna transformata Fouriera:

$$c[q] = \mathcal{F}^{-1}\{\ln |X[k]|\}. \quad (15)$$

Zmienna q jest nazywana quefrencją i odpowiada okresom składowych obecnych w sygnale. Dla sygnału mowy maksimum cepstrum w zakresie odpowiadającym częstotliwościom około 50–400 Hz może wskazywać okres tonu podstawowego. Po znalezieniu maksimum q^* częstotliwość tonu podstawowego obliczana jest jako:

$$f_0 = \frac{f_s}{q^*}. \quad (16)$$


Zaletą metody cepstralnej jest to, że pozwala rozdzielać informację o pobudzeniu krtanowym od obwiedni widma związanej z traktem głosowym. Wadą jest wrażliwość na jakość widma, obecność szumu oraz poprawny dobór zakresu quefrencji.



Rysunek 5: Wykres częstotliwości tonu podstawowego wyznaczonej metodą cepstrum dla nagrania własnego głosu.

5.11 Formanty

Formanty to lokalne maksima obwiedni widma mowy, związane z rezonansami traktu głosowego. Najczęściej analizuje się pierwsze formanty, oznaczane jako F_1 , F_2 i F_3 . Są one szczególnie ważne dla samogłosek, ponieważ położenie formantów zależy od ułożenia języka, ust i szczęki. W widmie lub na spektrogramie formanty można obserwować jako pasma o zwiększonej energii.



Rysunek 6: Porównanie tonu podstawowego wyznaczonego autokorelacją i AMDF dla tego samego nagrania.

6 Plan eksperymentów

6.1 Zestaw nagrań testowych

Zestaw nagrań obejmuje:

1. własny głos – kilka powtórzeń tej samej samogłoski, np. *a*,
2. własny głos – sekwencję kilku samogłosek, np. *a-e-i-o-u*,
3. głos drugiej osoby o innym zakresie wysokości,
4. fragment zawierający spółgłoski bezdźwięczne, np. *s*, *sz*, *f*,

Tabela 1: Opis użytych nagrań testowych.

Nagranie	Zawartość	Lektor
aba_2.wav	"aba"	28m
abe_2.wav	"abe"	28m
benzyna_1.wav	"benzyna"	23f
benzyna_2.wav	"benzyna"	28m
chrzaszcz_2.wav	"chrząszcz"	28m

6.2 Ustawienia bazowe

W większości testów można zastosować ustawienia bazowe:


- długość ramki: 60 ms,

- overlap: 50%,
- okno: Hann,
- maksymalna częstotliwość spektrogramu: 3000 Hz,


7 Wyniki działania programu

7.1 Porównanie formantów aba i abe

Na rysunkach 7 i 8 widać głoski *a* oraz *e*. Głoski *a* na obu wykresach mają bardzo podobne formanty, a głoska *e* na drugim wykresie jest wyraźnie inna.




Rysunek 7: spektrogram "aba"




Rysunek 8: spektrogram "abe"

7.2 Porównanie spektrogramu i tonu podstawowego różnych lektorów




Rysunek 9: spektrogram i ton podstawowy - mężczyzna



Rysunek 10: spektrogram i ton podstawowy - kobieta

7.3 Spektrogram i inne parametry spółgłosek bezdźwięcznych



Rysunek 11: różne parametry w słowie "chrząszcz"

Na rysunku 11 bardzo wyraźnie widać różnicę pomiędzy głoskami *ch*, *sz*, *cz* (wysokie rozproszone częstotliwości) a głoską *q* (niższe częstotliwości, formanty). Centroid oraz roll-off mają również wyższe wartości dla głosek bezdźwięcznych.

8 Dyskusja wyników

8.1 Różnice między analizą czasową i częstotliwościową

Cechy czasowe, takie jak *volume*, energia krótkoczasowa i ZCR, dobrze opisują zmienność amplitudy oraz ogólny charakter fragmentu sygnału. Nie pokazują jednak bezpośrednio, w jakich pasmach częstotliwości znajduje się energia. Analiza widmowa uzupełnia te informacje: centroid, roll-off i bandwidth pozwalają określić, czy sygnał jest raczej niski- czy wysokoczęstotliwościowy, a płaskość widmowa pomaga odróżniać fragmenty tonalne od szumowych.

8.2 Obserwacje dla samogłosek i spółgłosek

Samogłoski powinny mieć wyraźną strukturę harmoniczną oraz widoczne pasma formantowe. Ich widmo jest zwykle bardziej tonalne, dlatego płaskość widmowa może być niższa. Spółgłoski bezdźwięczne i szumowe mają bardziej rozproszoną energię, często w wyższych pasmach, dlatego mogą mieć wyższy centroid i roll-off. Różnice te powinny być zauważalne zarówno na wykresie FFT, jak i na spektrogramie.

8.3 Ograniczenia metod

Zastosowane metody są przejrzyste i łatwe do interpretacji, ale mają ograniczenia. Widmo krótkiego fragmentu silnie zależy od wyboru długości ramki i okna. Parametry widmowe są wrażliwe na szum oraz poziom nagrania. Cepstralna estymacja tonu podstawowego może dawać błędne wyniki dla fragmentów bezdźwięcznych, szumowych, muzycznych lub dla ramek, w których nie ma stabilnej periodyczności. Spektrogram wymaga dobrania rozsądnego kompromisu między rozdzielczością czasową i częstotliwościową.

W obecnej implementacji należy także uważać na wartości skrajne parametrów. Overlap powinien być mniejszy niż 100%, a dla bardzo cichych sygnałów normalizacja spektrogramu może wymagać dodatkowego zabezpieczenia przed dzieleniem przez bardzo małą wartość. Dodatkowo przy interpretacji osi czasu dla ramek z overlapem należy pamiętać, że rzeczywisty krok między ramkami zależy od ustawionego nakładania.

9 Problemy napotkane podczas realizacji

Podczas rozbudowy aplikacji najważniejsze problemy dotyczyły poprawnego przygotowania sygnału do analizy widmowej. Szczególnie istotny był wybór fragmentu do FFT, ponieważ widmo całego nagrania bywa trudne do interpretacji, gdy sygnał zawiera różne głoski, pauzy i zmiany intonacji. Drugim problemem był dobór funkcji okna i długości ramki. Krótka ramka poprawia lokalizację w czasie, ale pogarsza rozdzielczość częstotliwościową, natomiast długa ramka daje dokładniejsze widmo, ale może łączyć kilka różnych zjawisk w jednym wyniku.

Kolejną trudnością była interpretacja cepstrum. Metoda działa najlepiej dla fragmentów dźwięcznych, w których występuje wyraźna periodyczność. Dla szumu, ciszy lub spółgłosek bezdźwięcznych wynik może być niestabilny i nie powinien być traktowany jako wiarygodny ton podstawowy.

10 Wnioski

Aplikacja pozwala analizować sygnały audio w dziedzinie częstotliwości, rysować widmo FFT dla całego sygnału lub wskazanego fragmentu, stosować funkcje okienkowe, wyznaczać parametry widmowe, tworzyć spektrogram oraz obliczać ton podstawowy metodą cepstrum.

Analiza widmowa daje informacje, których nie widać bezpośrednio na przebiegu czasowym. Dzięki FFT można zauważyć składowe harmoniczne i pasma o największej energii. Parametry takie jak centroid, bandwidth, roll-off i flatness pozwalają liczbowo opisać charakter widma. Spektrogram pokazuje, jak widmo zmienia się w czasie, dlatego jest szczególnie użyteczny przy analizie mowy, gdzie kolejne głoski mają różne właściwości częstotliwościowe.

Na podstawie testów można oczekiwać, że samogłoski będą miały bardziej uporządkowane, harmoniczne widmo i widoczne formanty, natomiast spółgłoski bezdźwięczne będą bardziej szumowe i szerokopasmowe. Ton podstawowy wyznaczony cepstrum powinien być najbardziej stabilny dla fragmentów dźwięcznych, zwłaszcza samogłosek, i mniej wiarygodny dla ciszy oraz spółgłosek szumowych.

Wybór parametrów nie jest dowolny. Długość ramki, overlap, zakres częstotliwości spektrogramu i funkcja okna wpływają na czytelność wyników. Dlatego w praktycznej analizie należy dobierać je do badanego sygnału. Dla mowy dobrym punktem startowym jest ramka około 20–40 ms, okno Hann lub Hamming oraz overlap około 50%. Dla sygnałów muzycznych lub dokładniejszej analizy niskich częstotliwości warto sprawdzić również dłuższe ramki.