

Analiza i przetwarzanie dźwięku

Projekt 1 – Cechy sygnału audio w dziedzinie czasu

Sprawozdanie z projektu

Autorzy:

Bartosz Radomski, Wiktor Pańczak

Spis treści

1	Wstęp	3
2	Cel projektu i zakres wykonania	3
3	Opis aplikacji	4
3.1	Technologie i biblioteki	4
3.2	Interfejs użytkownika	4
4	Przebieg działania programu	5
5	Opis metod i implementacji	6
5.1	Wczytanie i normalizacja sygnału	6
5.2	Podział sygnału na ramki	6
5.3	Volume	6
5.4	Short-Time Energy	7
5.5	Zero Crossing Rate	7
5.6	Częstotliwość tonu podstawowego – autokorelacja	7
5.7	Częstotliwość tonu podstawowego – AMDF	8
5.8	Detekcja ciszy	8
5.9	Detekcja fragmentów dźwięcznych i bezdźwięcznych	8
5.10	Klasyfikacja mowa / muzyka	8
5.11	Cechy na poziomie całego klipu	9
5.12	Zapis wyników do plików	10
6	Plan eksperymentów	10
7	Wyniki badań	10
7.1	Nagranie 1 – (mowa + muzyka)	11
7.2	Nagranie 2 – mowa męska	12
7.3	Nagranie 3 – mowa żeńska	14
7.4	Nagranie 4 – muzyka	15
7.5	Zestawienie porównawcze	16

8	Dyskusja wyników	17
8.1	Wpływ doboru parametrów	17
8.2	Porównanie autokorelacji i AMDF	17
8.3	Ograniczenia zastosowanych metod	17
8.4	Problemy napotkane podczas realizacji	17
9	Wnioski	18

1 Wstęp

Celem projektu było opracowanie aplikacji okienkowej do analizy sygnału audio w dziedzinie czasu. Program wczytuje pliki **WAV**, wyznacza parametry na poziomie ramki i całego klipu, prezentuje przebieg czasowy oraz wybrane wykresy, a także umożliwia zapis wyników do plików tekstowych i **CSV**. W pracy szczególny nacisk położono na ręczną implementację obliczeń cech sygnału, bez korzystania z gotowych bibliotek realizujących analizę audio.

Zakres funkcjonalny aplikacji obejmuje wymagania podstawowe i rozszerzone, tj. wyświetlanie przebiegu czasowego sygnału, obliczanie cech ramkowych, detekcję ciszy, wyznaczanie częstotliwości tonu podstawowego metodą autokorelacji i AMDF, określanie fragmentów dźwięcznych i bezdźwięcznych, klasyfikację mowa/muzyka oraz wyznaczanie cech na poziomie całego klipu. Dodatkowo program zapisuje wyniki analizy do plików zewnętrznych.

2 Cel projektu i zakres wykonania

Wymagania projektowe obejmowały implementację aplikacji okienkowej z analizą cech sygnału audio w dziedzinie czasu, przy czym obliczenia miały zostać zrealizowane samodzielnie, a biblioteki mogły być użyte jedynie do obsługi interfejsu, wczytywania plików i rysowania wykresów.

W wykonanej aplikacji zrealizowano następujące elementy:

1. wczytywanie plików **WAV**,
2. wyświetlanie przebiegu czasowego sygnału,
3. obliczanie parametrów ramkowych: *volume*, *short-time energy*, *zero crossing rate*,
4. detekcję ciszy z zaznaczeniem jej na wykresie,
5. estymację tonu podstawowego metodą autokorelacji oraz AMDF,
6. wyznaczanie fragmentów dźwięcznych i bezdźwięcznych,
7. heurystyczną klasyfikację fragmentów jako mowa lub muzyka,
8. wyznaczanie parametrów na poziomie całego klipu,
9. eksport wyników do plików **CSV** i **TXT**,
10. dodatkowe cechy: współczynnik szczytu oraz znormalizowaną entropię energii.

3 Opis aplikacji

3.1 Technologie i biblioteki

Aplikacja została wykonana w języku **Python**. Dobór tego języka był uzasadniony szybkim prototypowaniem interfejsu graficznego oraz wygodną obsługą tablic numerycznych. W projekcie wykorzystano następujące biblioteki:

- `tkinter` – budowa interfejsu okienkowego,
- `scipy.io.wavfile` – wczytywanie plików WAV,
- `numpy` – operacje pomocnicze na tablicach oraz znak sygnału,
- `matplotlib` – generowanie wykresów,
- `csv` – zapis wyników do plików CSV,
- moduł `math` – obliczenia pierwiastka i logarytmu.


Należy podkreślić, że biblioteki nie realizują właściwej analizy cech audio. Obliczenia parametrów, takich jak energia krótkoczasowa, tempo przejść przez zero, autokorelacja czy AMDF, zostały zaimplementowane ręcznie w kodzie programu.

3.2 Interfejs użytkownika

Interfejs aplikacji składa się z kilku logicznych części:

1. sekcji wyboru pliku WAV,
2. sekcji ustawień parametrów analizy,
3. sekcji wyboru wykresów do wyświetlenia,
4. przycisków uruchamiających analizę i zapis wyników,
5. pola tekstowego prezentującego parametry całego klipu.

Użytkownik może określić długość ramki w milisekundach oraz progi używane przy detekcji ciszy. Następnie wybiera, które przebiegi lub wyniki klasyfikacji mają zostać pokazane na wykresie. Takie rozwiązanie umożliwia elastyczne porównywanie różnych parametrów bez przeładowania jednego okna zbyt dużą liczbą wykresów.



Rysunek 1: Zrzut ekranu interfejsu aplikacji po wczytaniu przykładowego nagrania i zaznaczeniu kilku parametrów analizy.

4 Przebieg działania programu

Po wybraniu pliku WAV program wczytuje sygnał i częstotliwość próbkowania. Jeżeli nagranie jest stereofoniczne, oba kanały są sumowane do jednego przebiegu. Następnie próbki są normalizowane do zakresu zmiennoprzecinkowego, zależnie od typu danych wejściowych. W dalszym kroku sygnał zostaje podzielony na ramki o długości zadanej przez użytkownika.

Na podstawie ramek obliczane są cechy sygnału. Uzyskane wyniki są wykorzystywane jednocześnie do rysowania wykresów, do klasyfikacji fragmentów sygnału oraz do wyznaczenia cech całego klipu. Po zakończeniu analizy program zapisuje pełen zestaw wyników w strukturze `last_analysis`, co pozwala później wyeksportować je do CSV lub TXT bez ponownego przetwarzania pliku.

Schemat działania programu można przedstawić jako ciąg operacji:

Wczytanie pliku WAV → normalizacja próbek → podział na ramki → obliczenie cech ramkowych → klasyfikacja fragmentów → obliczenie cech klipu → wizualizacja i eksport wyników

5 Opis metod i implementacji

5.1 Wczytanie i normalizacja sygnału

Po odczycie danych z pliku `WAV` program zamienia próbki na typ `float`. Dla danych 8-bitowych wykonywane jest przesunięcie oraz skalowanie, natomiast dla danych 16-bitowych i 32-bitowych stosowane jest dzielenie przez odpowiednią potęgę liczby 2. Dzięki temu niezależnie od formatu pliku dalsza analiza odbywa się na znormalizowanym przebiegu.

Jeżeli nagranie ma dwa kanały, program sumuje kanał lewy i prawy:

$$x[n] = x_L[n] + x_R[n]. \quad (1)$$

Takie rozwiązanie upraszcza dalszą analizę i sprowadza problem do sygnału jednowymiarowego.

5.2 Podział sygnału na ramki

Analiza cech w dziedzinie czasu jest wykonywana na krótkich fragmentach sygnału. Liczbę próbek w ramce obliczono ze wzoru:

$$N_f = f_s \cdot T_f, \quad (2)$$

gdzie f_s oznacza częstotliwość próbkowania, a T_f długość ramki wyrażoną w sekundach.

W testach stosowano głównie długość ramki równą **40 ms**. Taka wartość jest kompromisem pomiędzy stabilnością estymacji parametrów a rozdzielczością czasową wyników.

5.3 Volume

Pierwszym z obliczanych parametrów jest wartość *volume*, interpretowana tutaj jako wartość skuteczna sygnału w obrębie ramki:

$$V = \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} x^2[n]}. \quad (3)$$

Parametr ten opisuje średni poziom amplitudy w ramce i jest użyteczny przy detekcji ciszy oraz przy ogólnej ocenie intensywności sygnału.

5.4 Short-Time Energy

Energia krótkoczasowa jest zdefiniowana wzorem:

$$E = \frac{1}{N} \sum_{n=0}^{N-1} x^2[n]. \quad (4)$$

W porównaniu do *volume* parametr ten nie zawiera pierwiastka, dlatego silniej akcentuje większe wartości amplitudy. W praktyce dobrze pokazuje zmiany dynamiki sygnału w czasie.

5.5 Zero Crossing Rate

Tempo przejść przez zero określa, jak często sygnał zmienia znak w obrębie jednej ramki. Zostało ono wyznaczone ze wzoru:

$$ZCR = \frac{1}{2N} \sum_{n=1}^{N-1} |\text{sgn}(x[n]) - \text{sgn}(x[n-1])|. \quad (5)$$

Wartość *ZCR* jest zwykle większa dla sygnałów zawierających więcej składowych wysokoczęstotliwościowych lub szumowych. Parametr ten wspomaga detekcję ciszy oraz klasyfikację fragmentów dźwięcznych i bezdźwięcznych.

5.6 Częstotliwość tonu podstawowego – autokorelacja

Dla każdej ramki wyznaczana jest funkcja autokorelacji:

$$R[l] = \sum_{n=0}^{N-l-1} x[n] \cdot x[n+l], \quad (6)$$

gdzie l oznacza opóźnienie. Następnie wybierane jest takie opóźnienie l^* , dla którego wartość autokorelacji jest największa w zadanym zakresie. Częstotliwość tonu podstawowego obliczana jest ze wzoru:

$$f_0 = \frac{f_s}{l^*}. \quad (7)$$

W implementacji zakres poszukiwania ograniczono do częstotliwości od około 50 Hz do 400 Hz. Dodatkowo przed obliczeniem tonu podstawowego ramka może zostać podpróbkowana do około 8 kHz, aby ograniczyć koszt obliczeń.

5.7 Częstotliwość tonu podstawowego – AMDF

Drugą metodą estymacji tonu podstawowego jest *Average Magnitude Difference Function*:

$$D[l] = \frac{1}{N-l} \sum_{n=0}^{N-l-1} |x[n] - x[n+l]|. \quad (8)$$

W tej metodzie szukane jest opóźnienie l^* , dla którego funkcja *AMDF* przyjmuje najmniejszą wartość. Następnie częstotliwość tonu podstawowego ponownie wyznacza się jako $f_0 = f_s/l^*$. Metoda ta pozwala porównać wyniki z autokorelacją i ocenić, czy obie techniki zachowują się podobnie dla różnych nagrań.

5.8 Detekcja ciszy

Detekcja ciszy została oparta na dwóch cechach: *volume* i *ZCR*. Ramka jest uznawana za ciszę, jeżeli spełnione są jednocześnie warunki:

$$V < T_V \quad \text{oraz} \quad ZCR < T_{ZCR}, \quad (9)$$

gdzie T_V i T_{ZCR} są progami ustawianymi przez użytkownika. W testach domyślnie używano wartości $T_V = 0,01$ oraz $T_{ZCR} = 0,1$.

Zaletą takiego podejścia jest prostota i łatwość strojenia. Wadą pozostaje zależność od poziomu nagrania i charakteru zakłóceń tła.

5.9 Detekcja fragmentów dźwięcznych i bezdźwięcznych

Fragment uznawany jest za dźwięczny, jeśli:

- a) jego *volume* przekracza próg ciszy,
- b) jego *ZCR* nie jest zbyt duże,
- c) oszacowana częstotliwość tonu podstawowego mieści się w zakresie od 70 Hz do 400 Hz.

Takie kryterium odpowiada intuicji fonetycznej: fragmenty dźwięczne mają wyraźną periodyczność i zwykle mniejszą liczbę przejść przez zero niż fragmenty bezdźwięczne.

5.10 Klasyfikacja mowa / muzyka

Klasyfikacja mowy i muzyki została zrealizowana heurystycznie. Dla każdej niecichej ramki wyznaczane są dwa wyniki punktowe: *speech_score* i *music_score*. Na ocenę wpływają

następujące kryteria:

- zakres tonu podstawowego – wartości typowe dla mowy zwiększają *speech_score*,
- zakres *ZCR* – wartości charakterystyczne dla mowy premują klasę mowy,
- poziom głośności względem mediany *volume* w nagraniu,
- stabilność tonu podstawowego między sąsiednimi ramkami – większa stabilność zwiększa *music_score*.

Ostateczna decyzja jest podejmowana na podstawie porównania obu ocen punktowych. Jeżeli ramka została wcześniej oznaczona jako cisza, otrzymuje osobną etykietę **silence**. Jest to rozwiązanie proste i łatwe do interpretacji, ale nie gwarantuje poprawnej klasyfikacji dla wszystkich nagrań, zwłaszcza w przypadku sygnałów mieszanych lub silnie zaszumionych.

5.11 Cechy na poziomie całego klipu

Oprócz parametrów ramkowych program wyznacza także cechy opisujące całe nagranie. Są to między innymi:

- czas trwania klipu,
- częstotliwość próbkowania,
- liczba próbek i liczba ramek,
- *clip_rms*,
- *clip_energy*,
- *clip_zcr*,
- średnie wartości *volume*, *STE* i *ZCR* z ramek,
- średnia częstotliwość tonu podstawowego dla ramek dźwięcznych,
- udział ciszy, udział fragmentów dźwięcznych,
- udział mowy i muzyki,
- dominująca zawartość nagrania,
- współczynnik szczytu *crest factor*,
- znormalizowana entropia energii.

Współczynnik szczytu określono jako:

$$CF = \frac{\max |x[n]|}{RMS}, \quad (10)$$

a znormalizowaną entropię energii wyznaczono na podstawie rozkładu energii ramek:

$$H = - \sum_{i=1}^M p_i \log_2 p_i, \quad (11)$$

gdzie p_i oznacza udział energii i -tej ramki w całkowitej energii wszystkich ramek.

5.12 Zapis wyników do plików

Program umożliwia zapis wyników do plików **CSV** i **TXT**. Format **CSV** zawiera zarówno cechy klipu, jak i szczegółowe dane dla każdej ramki. Format **TXT** zapisuje podsumowanie parametrów oraz etykiety klasyfikacji mowa/muzyka dla kolejnych ramek. Funkcja ta ułatwia dalszą analizę porównawczą i dokumentowanie wyników.

6 Plan eksperymentów

Aby rzetelnie ocenić działanie programu, analizę przeprowadzono dla kilku różnych nagrań. Zestaw testowy obejmuje:

1. nagranie radiowe zawierające mowę i muzykę,
2. mowę męską,
3. mowę żeńską,
4. fragment muzyczny.


Dla każdego przypadku program uruchamiano z tymi samymi ustawieniami bazowymi, a następnie wykonywano dodatkowe testy z innymi progami lub inną długością ramki. Takie postępowanie pozwala porównać stabilność metod i ocenić wpływ parametrów na wynik.

7 Wyniki badań


Poniższe podrozdziały przedstawiają wyniki dla poszczególnych typów nagrań. Miejsca na wykresy i tabele pozostawiono do uzupełnienia danymi eksperymentalnymi.

7.1 Nagranie 1 – (mowa + muzyka)


Analizowane nagranie zawiera fragmenty mowy przeplatane muzyką. Jest to ważny przypadek testowy, ponieważ umożliwia jednoczesną ocenę detekcji ciszy, stabilności tonu podstawowego oraz skuteczności klasyfikacji mowa/muzyka.



Rysunek 2: Przebieg czasowy nagrania z zaznaczonymi obszarami ciszy, mowy i muzyki.



Rysunek 3: Wykresy *volume*, *STE* i *ZCR* dla nagrania.




Rysunek 4: Porównanie estymacji tonu podstawowego metodą autokorelacji i AMDF dla nagrania radiowego.

Tabela 1: Wybrane parametry klipu dla nagrania radiowego.


Parametr	Wartość
Czas trwania [s]	132.1211
Średnie <i>clip_rms</i>	0.226639
Udział ciszy	0.0027
Udział mowy	0.5816
Udział muzyki	0.4184
Dominująca zawartość	speech

7.2 Nagranie 2 – mowa męska

Nagranie mowy męskiej pozwala sprawdzić, czy estymacja tonu podstawowego dobrze działa dla niższych częstotliwości i czy fragmenty dźwięczne są wyznaczane stabilnie.



Rysunek 5: Przebieg czasowy i wykresy cech dla nagrania mowy męskiej.




Rysunek 6: Wykres tonu podstawowego dla nagrania mowy męskiej.

Tabela 2: Wybrane parametry klipu dla nagrania mowy męskiej.


Parametr	Wartość
Czas trwania [s]	1.5
Średni ton podstawowy ramek dźwięcznych [Hz]	122.26
Udział fragmentów dźwięcznych	0.7632
Udział ciszy	0.2368

7.3 Nagranie 3 – mowa żeńska

Nagranie mowy żeńskiej jest dobrym testem dla wyższych częstotliwości tonu podstawowego. Pozwala to sprawdzić, czy przyjęty zakres opóźnień oraz częstotliwości jest odpowiedni również dla tego typu sygnału.



Rysunek 7: Przebieg czasowy i wykresy cech dla nagrania mowy żeńskiej.




Rysunek 8: Wykres tonu podstawowego dla nagrania mowy żeńskiej.

Tabela 3: Wybrane parametry klipu dla nagrania mowy żeńskiej.


Parametr	Wartość
Czas trwania [s]	1.6546
Średni ton podstawowy ramek dźwięcz- nych [Hz]	208.488
Udział fragmentów dźwięcznych	0.5476
Udział ciszy	0.3095

7.4 Nagranie 4 – muzyka

Nagranie muzyczne pozwala ocenić, czy heurystyczna klasyfikacja poprawnie odróżnia muzykę od mowy. Jest to również przypadek, w którym mogą wystąpić fragmenty silnie tonalne oraz fragmenty perkusyjne o dużym ZCR .



Rysunek 9: Przebieg czasowy i wykresy cech dla nagrania muzycznego.



Rysunek 10: Wyniki klasyfikacji mowa/muzyka dla nagrania muzycznego.

Tabela 4: Wybrane parametry klipu dla nagrania muzycznego.

Parametr	Wartość
Czas trwania [s]	32.9927
Udział muzyki	0.3246
Udział mowy	0.6754
Udział ciszy	0.0255

7.5 Zestawienie porównawcze

Po przeprowadzeniu wszystkich testów warto zebrać najważniejsze wyniki w jednej tabeli porównawczej.

Tabela 5: Porównanie wyników dla różnych nagrań.

Typ nagrania	Średni f_0 [Hz]	Udział ci-szy	Udział dźwięcz-nych	Udział mowy
Mowa + muzyka	334.738	0.0027	0.9258	0.5816
Mowa męska	122.26	0.2368	0.7632	0.8276
Mowa żeńska	208.488	0.3095	0.5476	0.9655
Muzyka	112.466	0.0255	0.7479	0.6754

8 Dyskusja wyników

Na podstawie przeprowadzonych testów sformułowano obserwacje dotyczące działania programu.

8.1 Wpływ doboru parametrów

Największy wpływ na wyniki mają długość ramki oraz progi używane przy detekcji ciszy. Zbyt krótka ramka daje większą rozdzielczość czasową, ale może prowadzić do niestabilnej estymacji tonu podstawowego. Zbyt długa ramka stabilizuje parametry, jednak pogarsza lokalizację zmian w sygnale. Podobnie progi detekcji ciszy muszą być dostosowane do poziomu nagrania – wartości zbyt małe pomijają ciche fragmenty, a wartości zbyt duże mogą błędnie oznaczać słabą mowę jako ciszę.

8.2 Porównanie autokorelacji i AMDF

Autokorelacja i AMDF rozwiązują ten sam problem, ale wykorzystują inne kryterium dopasowania. W praktyce autokorelacja często lepiej uwidacznia periodyczność sygnału, natomiast AMDF bywa bardziej odporna na niektóre lokalne zakłócenia.

8.3 Ograniczenia zastosowanych metod

Zastosowane algorytmy są celowo proste i czytelne, ale mają kilka ograniczeń:

- są wrażliwe na dobór progów i poziom nagrania,
- nie uwzględniają filtracji wstępnej ani okienkowania ramek,
- klasyfikacja mowa/muzyka jest heurystyczna, więc może mylić sygnały pośrednie,
- estymacja tonu podstawowego nie zawsze działa poprawnie dla fragmentów szumowych lub bardzo złożonych harmonicznie.

Mimo tych ograniczeń projekt dobrze pokazuje, jak wiele informacji o sygnale można uzyskać już na podstawie prostych cech w dziedzinie czasu.

8.4 Problemy napotkane podczas realizacji

Podczas realizacji napotkano następujące trudności:

1. dobór sensownego zakresu opóźnień dla tonu podstawowego,

2. różne poziomy nagrań wejściowych i konieczność strojenia progów,
3. przypadki, w których klasyfikacja mowa/muzyka nie była jednoznaczna,
4. dobór takiej liczby wykresów, aby zachować czytelność interfejsu.

9 Wnioski

Na podstawie wykonanej implementacji i przeprowadzonych eksperymentów można stwierdzić, że analiza sygnału audio w dziedzinie czasu pozwala skutecznie opisać podstawowe właściwości nagrania. Parametry takie jak *volume*, energia krótkoczasowa i *ZCR* dobrze pokazują lokalne zmiany sygnału, natomiast autokorelacja i *AMDF* umożliwiają wyznaczenie tonu podstawowego w fragmentach o wyraźnej strukturze periodycznej.

Detekcja ciszy oraz podział na fragmenty dźwięczne i bezdźwięczne działają poprawnie pod warunkiem rozsądnego doboru progów. Klasyfikacja mowa/muzyka oparta na prostych regułach może dawać użyteczne wyniki, jednak jej skuteczność zależy od charakteru nagrania i nie dorównuje metodom opartym na bardziej zaawansowanych modelach. Z drugiej strony zaletą tej metody jest pełna przejrzystość oraz możliwość łatwego wyjaśnienia, dlaczego dana decyzja została podjęta.